





TRABAJO FINAL DATA SCIENCE 2

Machine Learning para predicción de fallas en turbinas


VICTORIA PALMA



INTRODUCCIÓN

Dentro de una industria es esencial realizar el seguimiento de variables, no solo de aquellas que impactan en los resultados financieros, sino también de las que influyen en el desempeño de la producción.

El área de mantenimiento realiza mediciones de manera recurrente para prevenir futuros perjuicios en los equipos e instalaciones. De este modo, se busca no comprometer la seguridad de los activos ni de las personas dentro del establecimiento



HIPÓTESIS


Combinando conocimientos técnicos en mecánica con los aprendizajes adquiridos durante el cursado de Data Science en CoderHouse, se propone desarrollar un modelo de Machine Learning capaz de predecir la falla de una turbina bajo determinados valores de variables físicas, tales como:

- Presión
- Temperatura del equipo
- Humedad
- Vibraciones mecánicas

El modelo será entrenado utilizando un dataset ficticio obtenido desde Kaggle.



ANÁLISIS EXPLORATORIO DE DATOS



1

Tras realizar el proceso de data wrangling, se obtuvo la matriz de correlación entre las variables del sistema

2

Los resultados indican que Vibraciones, Presión y Temperatura de operación son las tres variables con mayor influencia en la probabilidad de falla de la turbina

3

Estos resultados son coherentes con principios de ingeniería mecánica y mantenimiento predictivo:

- Vibraciones: son un indicador crítico de condición en equipos rotativos y afectan directamente la vida útil de rodamientos, acoplamientos y ejes.
- Presión y Temperatura de operación: definen las condiciones de funcionamiento de la turbina. Desviaciones sostenidas pueden indicar operación fuera de diseño y contribuir al desgaste acelerado de componentes, incluyendo posibles fenómenos de erosión en los álabes.



COMPARACIÓN DE ALGORÍTMOS



Resumen

Se entrenaron modelos de aprendizaje supervisado, específicamente Regresión Logística y Random Forest.

Como se observa en la tabla comparativa, el modelo Random Forest presenta mejores valores, superando a la Regresión Logística.

En base a estos resultados, Random Forest fue seleccionado como el modelo final para continuar con el análisis.

MÉTRICA	QUE MIDE?	RANDOM FOREST	REGRESIÓN LOGÍSTICA
ACCURACY	PROPORCIÓN DE PREDICCIONES CORRECTAS	0.9786	0.9474
PRECISION	¿QUE TAN CONFIABLE ES EL MODELO CUANDO DICE "POSITIVO"?	0.9167	0.9615
RECALL	¿QUÉ TAN BIEN ENCUENTRA EL MODELO LOS POSITIVOS REALES	0.8627	0.4902
F1 SCORE	BALANCE ENTRE PRECISIÓN Y RECALL	0.8889	0.6494

OPTIMIZACIÓN CON HIPERPARÁMETROS


Luego del entrenamiento inicial, se realizó un proceso de optimización de hiperparámetros con el objetivo de mejorar la capacidad de generalización del modelo y reducir el riesgo de sobreajuste frente a nuevos datos en un entorno productivo.

Para ello, el modelo de Random Forest fue optimizado utilizando GridSearchCV, un método computacionalmente más costoso pero más exhaustivo que RandomizedSearchCV.


Como resultado de la optimización, se obtuvo una mejora en la métrica Accuracy, alcanzando un valor de 0.9844, lo que representa un incremento del 0.59% respecto al modelo base.

- Accuracy en conjunto de test (modelo base): 0.9786
- Accuracy del modelo optimizado: 0.9844

Dado que la diferencia entre ambos valores es menor a 0.02, se concluye que el modelo no presenta indicios significativos de sobreajuste y mantiene una adecuada capacidad de generalización.



CONCLUSIONES FINALES




Identificación de variables críticas

Las vibraciones, la presión y la temperatura de operación se identificaron como las principales variables que influyen en la probabilidad de falla de la turbina




Desarrollo de modelo predictivo

La construcción de un modelo de Machine Learning permitió generar una herramienta de apoyo a la toma de decisiones para el área de mantenimiento, orientada a la detección temprana de fallas.



Nueva herramienta sin inversión adicional

El aprovechamiento de los datos ya disponibles en la industria para la toma de decisiones permite implementar una herramienta efectiva de prevención de fallas sin necesidad de inversión en nuevos equipos, requiriendo únicamente desarrollo y mantenimiento de código



Integración con la ingeniería mecánica tradicional

La incorporación de tecnologías de Data Science en procesos de ingeniería mecánica tradicionales amplía y fortalece el conjunto de herramientas disponibles para la toma de decisiones técnicas y estratégicas.

Gracias

