




TRABAJO FINAL DATA SCIENCE 2

Anomalías en equipos industriales


VICTORIA PALMA



INTRODUCCIÓN

Dentro de una industria es esencial realizar seguimiento de las variables. No solo de las que tienen incidencia en resultados financieros sino también en el desempeño de la producción.

El área de mantenimiento realiza mediciones recurrentes para evitar futuros prejuicios de los equipamientos e instalaciones. Así se busca no comprometer la seguridad de los mismos y de las personas dentro del establecimiento.



HIPÓTESIS


Combinando los conocimientos técnicos mecánicos junto con lo aprendido durante el cursado de data science en CoderHouse, se buscará crear un modelo de Machine Learning que prediga cuando una turbina fallará bajo ciertos valores de variables físicas como:

- Presión
- Temperatura del equipo
- Humedad
- Vibraciones mecánicas

El modelo será entrenado con un dataset ficticio obtenido desde Kaggle.



VARIABLES CRÍTICAS



1

Después de realizar el proceso de data wrangling, se obtuvo la matriz de correlación


2

Vibraciones, Presión y Temperatura de trabajo son las tres principales variables que influyen en la probabilidad de falla de la turbina

3

Esto concuerda con los principios de mecánica general

- Vibraciones: Impactan sobre la vida útil de acoplamientos, ejes
- Valores inadecuados de Presión y Temperatura: Generan disminución de la calidad del vapor de la turbina, generando erosión en los álabes



COMPARACIÓN DE ALGORÍTMOS



MÉTRICA	QUE MIDE?	RANDOM FOREST	REGRESIÓN LOGÍSTICA
ACCURACY	PROPORCIÓN DE PREDICCIONES CORRECTAS	0.9786	0.9474
PRECISION	¿QUE TAN CONFIABLE ES EL MODELO CUANDO DICE "POSITIVO"?	0.9167	0.9615
RECALL	¿QUÉ TAN BIEN ENCUENTRA EL MODELO LOS POSITIVOS REALES	0.8627	0.4902
F1 SCORE	BALANCE ENTRE PRECISIÓN Y RECALL	0.8889	0.6494

Resumen

Random Forest fue el algoritmo de aprendizaje supervisado que mejores resultados entregó

Por ello, ese será con el cual se continuará trabajando.

OPTIMIZACIÓN CON HIPERPARÁMETROS


Luego de entrenar el modelo, es necesario realizar ciertas optimizaciones para que el modelo sea flexible. Con ello se busca que una vez que sea lanzado a producción y esté frente a nuevos datos y no tenga sobreajuste.

Para ello, el modelo de Random Forest se optimizó con GridSeachCV. Método computacionalmente caro, pero más exhaustivo que RandomizedSearchCV


Se mejoró el valor de Accuracy a 0.9844 (0.59%)

- Accuracy en test: 0.9786
- Accuracy modelo optimizado: 0.9844

Como la mejora es menor a 0.02, se puede concluir que no hay sobreajuste.



CONCLUSIONES FINALES




Detección de variables críticas

Vibraciones, presiones y temperaturas de trabajo son las tres principales variables que influyen en la incidencia de fallas de nuestra turbina




Creación de modelo predictivo

Al haber obtenido un modelo de predicción, hemos creado una herramienta de apoyo para la toma de decisiones en el área de mantenimiento.



Nueva herramienta sin inversión

El hecho de explotar los datos disponibles en una industria para la toma de decisiones, significa la obtención de una excelente herramienta de prevención de fallas con costo nulo. No requiere de inversión. Solo de unas cuantas líneas de código



Integración con mecánica tradicional

La integración de nuevas tecnologías en procesos tradicionales, puede enriquecer la cantidad de herramientas disponibles para la toma de decisiones

Gracias

